智能阅读器自制 PDF 样本

1 研究目标

本样本包含中文、English terms、脚注提示和页眉页脚，用于验证正文、标题、段落、页码和引用定位。

2 关键结论

解析结果不能只保留扁平纯文本。每个文本块还需要稳定 ID、标题路径、物理页码和原始位置。

字段	示例值	风险
physical_page	2	封面导致打印页码偏移
heading_path	1 > 2	标题层级可能被误判

脚注：这是一个可回溯的脚注占位，用来检查脚注是否被混入正文。