智能阅读器自制 PDF 样本

跨栏标题和参考文献会故意让阅读顺序变得敏感。

1 研究目标

本样本包含中文、English terms、脚注提示和页眉页脚，用于验证正文、标题、段落、页码和引用定位。

2 关键结论

解析结果不能只保留扁平纯文本。每个文本块还需要稳定 ID、标题路径、物理页码和原始位置。

字段	示例值	风险
physical_page	2	封面导致打印页码偏移
heading_path	1 > 2	标题层级可能被误判

脚注：这是一个可回溯的脚注占位，用来检查脚注是否被混入正文。

左栏补充段落：阅读顺序应先完成当前栏，再进入同页另一栏；解析器不能把页脚插入正文。

右栏内容

右栏补充段落：引用定位需要同时记录物理页码、文本块和坐标，表格应保持行列关系。

3 参考文献

[1] A. Reader. Document provenance and evidence blocks. 2026.

4 第二页

第二页用于检查页码、跨页段落和引用位置。